

Taller #2

Julián David Sánchez Gómez (123758)

Nicolás Andrés chacón Sueca (123692)

Universidad ECCI

Asignatura

Sistemas avanzados de producción

Docente

Fredy Alexander Orjuela Lopez

12 de abril del 2026

Fase 1: Desarrollo Analítico: Regularización Ridge.

Representación vectorial

La función original es:

$$J(\beta) = \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

Forma matricial:

Definimos:

- $Y \in R^{n \times 1}$
- $X \in R^{n \times p}$
- $\beta \in R^{p \times 1}$

Entonces

$$J(\beta) = (Y - X\beta)^T (Y - X\beta) + \lambda \beta^T \beta$$

Expansión de la formula cuadrática

$$(Y - X\beta)^T (Y - X\beta) = Y^T Y - Y^T X\beta - \beta^T X^T Y + \beta^T X^T X\beta$$

Como los escalares son iguales:

$$Y^T X\beta = (Y^T X\beta)^T = \beta^T X^T Y$$

$$(Y - X\beta)^T (Y - X\beta) = Y^T Y - 2\beta^T X^T Y + \beta^T X^T X\beta$$

$$J(\beta) = Y^T Y - 2\beta^T X^T Y + \beta^T X^T X\beta + \lambda \beta^T \beta$$

Condición de primer orden (gradiente)

Derivadas:

$$\frac{\partial}{\partial \beta} (Y^T Y) = 0$$

$$\frac{\partial}{\partial \beta} (-2\beta^T X^T Y) = -2X^T Y$$

$$\frac{\partial}{\partial \beta} (\beta^T X^T X \beta) = 2X^T X \beta$$

$$\frac{\partial}{\partial \beta} (\lambda \beta^T \beta) = 2\lambda \beta$$

Entonces

$$\nabla J(\beta) = -2X^T Y + 2X^T X \beta + 2\lambda \beta$$

$$-2X^T Y + 2X^T X \beta + 2\lambda \beta = 0$$

$$-X^T Y + X^T X \beta + \lambda \beta = 0$$

Solución cerrada

$$X^T X \beta + \lambda \beta = X^T Y$$

$$(X^T X + \lambda I) \beta = X^T Y$$

$$\beta_{Ridge} = (X^T X + \lambda I)^{-1} X^T Y$$

Preguntas fase 1

1. ¿Porque la suma de λI garantiza que la matriz resultante sea invertible incluso si X^T es singular (no invertible)?

$X^T X$ puede ser singular (no invertible) cuando Hay multicolinealidad (variables altamente correlacionadas) o cuando hay más variables que observaciones ($p > n$). Esto significa que su determinante es 0. Entonces cuando sumamos $X^T X + \lambda I$ estamos modificando la matriz de forma estructural.

Si $X^T X$ tienes valores propios

$$\lambda_1, \lambda_2, \dots, \lambda_p$$

Algunos pueden ser 0 por eso no es invertible.

Por otro lado, si sumamos λI los nuevos valores propios son:

$$\lambda_1 + \lambda, \lambda_2 + \lambda, \dots, \lambda_p + \lambda$$

Como $\lambda > 0$ entonces:

$$\lambda_1 + \lambda > 0$$

2. Efecto del Parámetro λ : ¿Que sucede con el modelo y sus coeficientes cuando $\lambda \rightarrow 0$? ¿Y qué ocurre cuando $\lambda \rightarrow \infty$? Explique en términos de la complejidad del modelo (Sesgo vs. Varianza).

Caso 1: cuando $\lambda \rightarrow 0$

$$\beta_{Ridge} = (X^T X + \lambda I)^{-1} X^T Y$$

Se convierte en:

$$\beta = (X^T X + \lambda I)^{-1} X^T Y$$

este modelo produce coeficientes grandes, y vuelve el modelo más flexible y con un sesgo bajo. Aunque el modelo presenta una alta varianza,

Caso 2: $\lambda \rightarrow \infty$

$$\lambda I$$

Entonces:

$$\beta \approx 0$$


Este modelo tiene como efecto que:

- Los coeficientes tienden a 0
- Es un modelo simple
- Tiene alta regularización
- Tiene un sesgo alto y
- Una baja varianza

Fase 2: Optimización Numérica y Descenso de Gradiente

1. Impacto tasa de aprendizaje


learning rate elevado (0,6)




Análisis

la trayectoria no logra llegar al centro de las curvas de nivel. De hecho, diverge rápidamente, esto sugiere que la tasa de aprendizaje es probablemente demasiado alta, lo que hace que el algoritmo "salte" sobre los mínimos y se vaya a valores infinitos.

learning rate 0,0001 = 10^{-4}



learning rate 0,00001 = 10^{-5}




Análisis

al reducir la tasa de aprendizaje a 10^{-5} con el número de iteraciones en 1000, no alcanza a llegar al mínimo de la curva de nivel debido a que su tasa de aprendizaje es muy bajo, no obstante, cuando la aumentamos un poco más, un punto intermedio, a 10^{-4} , se logra observar un equilibrio en la tasa, lo que provoca que con 1000 iteraciones consiga alcanzar un mínimo en las curvas de nivel.

2. Dependencia del punto inicial

Start point (5.0, -5.0)



Observamos en la gráfica como tiende a dirigirse a hacia el mínimo local más cercano a su punto de origen. Esto quiere decir que con un número de iteraciones adecuado y un learning rate moderado, siempre alcanzara su mínimo local más cercano.

Preguntas fase 2

1. El fenómeno de “Overshooting”: Explique físicamente que ocurre cuando el paso ($\eta \cdot \nabla f$) es más grande que la distancia al mínimo. ¿Cómo se visualiza esto en el gráfico de curvas de nivel?

Respuesta

El fenómeno de "Overshooting" (o sobrepaso) en el Descenso del Gradiente ocurre cuando el tamaño del paso que toma el algoritmo es demasiado grande en relación con la distancia al mínimo. Cuando el paso $\eta \cdot \nabla f$ es mayor que la distancia al mínimo, el algoritmo "salta" por encima del mínimo. En lugar de acercarse, puede terminar en un punto donde el valor de la función es mayor que en el punto anterior, o incluso en el otro lado del mínimo, pero más lejos.

en el Gráfico de Curvas de Nivel la trayectoria del algoritmo no se mueve suavemente hacia el centro. En cambio, cruzaría las curvas de nivel, iría más allá del centro, y luego volvería a cruzar en la dirección opuesta, o zigzaguearía alrededor del mínimo.

En el caso más extremo, si la divergencia ocurre, la trayectoria se alejaría rápidamente del centro de las curvas de nivel, moviéndose hacia las curvas exteriores (representando valores de función mucho más altos), e incluso saliendo de la región visualizada del gráfico, como ocurrió en nuestra primera simulación con la tasa de aprendizaje de 0.6

2. Si el algoritmo se detiene en la iteración 1000 pero aún se encuentra lejos del mínimo, ¿qué estrategia es mejor: aumentar el número de iteraciones o ajustar la tasa de aprendizaje? Justifique su respuesta.

Respuesta

Si el algoritmo se detiene en la iteración 1000 y aún se encuentra lejos del mínimo, la estrategia más efectiva y fundamental es ajustar la tasa de aprendizaje (learning rate), Ya que la tasa de aprendizaje determina el tamaño de cada paso que el algoritmo toma en la

dirección del gradiente. Si el algoritmo está lejos del mínimo y avanza lentamente, podría significar que la tasa de aprendizaje es demasiado pequeña. En este caso, aumentar la tasa de aprendizaje con precaución permitirá al algoritmo dar pasos más grandes y, alcanzar el mínimo mucho más rápido.

3. En un problema de ingeniería con cientos de variables (como la optimización de una cadena de suministro), ¿por qué es peligroso confiar en un único punto de inicio aleatorio?

Respuesta

En un problema de ingeniería con cientos de variables como la optimización de una cadena de suministro confiar en un único punto de inicio aleatorio para algoritmos como el descenso del gradiente es muy peligroso, debido a que, las funciones de costo u objetivo en problemas de alta dimensión suelen ser extremadamente complejas, esto significa que tienen numerosos mínimos locales, que son puntos donde la función es más baja que en sus alrededores inmediatos, pero no necesariamente el valor más bajo de toda la función (el mínimo global).

Un algoritmo de descenso del gradiente, por su naturaleza, tiende a converger al mínimo local más cercano al punto de inicio. Si se usa un solo punto de inicio, el algoritmo casi con certeza encontrará solo uno de esos mínimos locales, y no hay garantía de que sea el mínimo global (la solución óptima real). Y si el algoritmo converge a un mínimo local pobre, las decisiones tomadas basándose en esa optimización serán ineficientes. Por ejemplo, una cadena de suministro optimizada a un mínimo local podría seguir incurriendo en costos excesivos o tener cuellos de botella no resueltos, a pesar de que existe una configuración globalmente más eficiente.

Fase 3: Redes Neuronales (MLP) y Ajuste de Hiperparametros

Parte A: Evaluación de Métricas de Regresión

Preguntas fase 3A

1. Explique la diferencia técnica entre el Error Absoluto Medio (MAE) y la Raíz del Error Cuadrático Medio (RMSE). ¿Cuál de las dos penaliza con mayor severidad

los errores grandes (outliers) en las ventas y por qué? Todo esto según los valores obtenidos en la imagen.

Respuesta

El MAE mide el error promedio absoluto, asignando el mismo peso a todas las desviaciones, mientras que el RMSE eleva los errores al cuadrado antes de promediarlos, lo que lo hace más sensible a errores grandes. En los resultados obtenidos, el RMSE es considerablemente mayor que el MAE tanto en entrenamiento como en prueba, lo que indica la presencia de outliers en las predicciones del modelo. Por lo tanto, el RMSE penaliza con mayor severidad los errores grandes en las ventas debido a su naturaleza cuadrática.

Resultados MAE, RMSE Y R2

```
/usr/local/lib/python3.12/dist-packages/sklearn/neural_network/_multilayer_perceptron.py:691: ConvergenceWarning:
Stochastic Optimizer: Maximum iterations (200) reached and the optimization hasn't converged yet.

== MLPRegressor ==
Train -> MAE: 47.086 | RMSE: 68.547 | R2: 0.858
Test -> MAE: 47.175 | RMSE: 69.458 | R2: 0.848
```

2. Si el R^2 en el conjunto de entrenamiento es significativamente mayor que en el de prueba, ¿qué fenómeno está ocurriendo? Proponga una solución basada en lo aprendido en la Fase 1.



Respuesta


Si el R^2 en entrenamiento es significativamente mayor que en prueba, el modelo presenta overfitting, lo que indica que ha aprendido demasiado bien los datos de entrenamiento pero no generaliza correctamente a nuevos datos. Una solución es aplicar regularización Ridge (L2), la cual añade un término de penalización a la función de costo que restringe el tamaño de los coeficientes. Esto reduce la complejidad del modelo, disminuye la varianza y mejora su capacidad de generalización.

3. Interpretación de Residuos: Al observar la gráfica de y real vs y pred, ¿se identifica algún patrón de error sistemático (ej. subestimación en ventas altas)?

Respuesta

```
== MLPRegressor ==  
Train -> MAE: 47.086 | RMSE: 69.547 | R2: 0.858  
Test  -> MAE: 47.175 | RMSE: 69.458 | R2: 0.848
```





La gráfica de valores reales vs predichos presenta un patrón sistemático de error, en el que el modelo tiene la tendencia de subestimar las ventas cuando son altas; esto se puede observar porque, en ese rango, los puntos están agrupados por debajo de la línea diagonal. Esto señala que el modelo no refleja correctamente los extremos de la distribución. Asimismo, el histograma de residuos muestra una distribución que se centra cerca de cero, pero tiene colas, lo que indica que existen errores significativos. En general, esto muestra que el modelo tiene limitaciones para generalizar en valores altos.

Parte B: Optimización con GridSearchCV




Arquitectura (hidden layer sizes): Compare una red “profunda” (más capas, ej. (32,16,8,4)) contra una “ancha” (una sola capa con muchas neuronas, ej. (64,)).

Comparación red profunda y red ancha:

GridSearchCV tomó: 107.03 s

== Resultado de la búsqueda (cv) ==
Mejores hiperparámetros: {'alpha': 0.1, 'hidden_layer_sizes': (32, 16, 8, 4), 'learning_rate_init': 0.001}
RMSE CV (aprox): 70.84929151642406

== MLP (MEJOR MODELO) ==
Train -> MAE: 42.910 | RMSE: 63.206 | R2: 0.890
Test -> MAE: 46.331 | RMSE: 68.949 | R2: 0.850



```


Ejecutando RandomizedSearchCV con espacio AMPLIO...
Fitting 3 folds for each of 50 candidates, totalling 150 fits
Fitting 3 folds for each of 50 candidates, totalling 150 fits
RandomizedSearchCV took: 3096.40 s

== Resultado de la búsqueda aleatoria (CV) ==
Mejores hiperparámetros: {'activation': 'relu', 'alpha': np.float64(0.00028006820077310237), 'hidden_layer_sizes': (64, 32), 'learning_rate': 'adaptive', 'learning_rate_init': np.float64(0.0015572825002401862)}
MSE CV (aprox): 67.963065890634

== MLP (MEJOR MODELO - Random Search amplio) ==
Train -> MAE: 42.543 | RMSE: 62.060 | R2: 0.894
Test -> MAE: 44.954 | RMSE: 65.901 | R2: 0.863


```

MLP (mejor, Random Search amplio): y_real vs y_pred (TEST)




10 de 20

MLP (mejor, Random Search amplio): Histograma de residuales (TEST)



MLP (mejor, Random Search amplio): Curva de pérdida (train)



Característica	GridSearchCV (Búsqueda 1)	RandomizedSearchCV (Búsqueda 2)	Impacto / Observación
Arquitectura (hidden_layer_sizes)	(32, 16, 8, 4)	(64, 32)	La búsqueda aleatoria prefirió una red más ancha y menos profunda.
Regularización (alpha)	0.1	0.000289	El modelo 2 requiere mucha menos penalización para generalizar.
Aprendizaje (learning_rate_init)	0.001	0.001557	Valores similares, ligeramente más alto en la búsqueda aleatoria.

Regularización (alpha): Conecte esto con la Fase 1. Pruebe valores como [1e-5, 1e-2, 1.0]. ¿Cómo afecta un α muy elevado a la capacidad de aprendizaje?

Un valor muy elevado de α (regularización L2) penaliza fuertemente los pesos del modelo, forzándolos a valores cercanos a cero. Esto reduce significativamente la capacidad de aprendizaje del modelo, impidiéndole capturar patrones complejos en los datos. Como resultado, el modelo se vuelve demasiado simple, presentando alto sesgo y bajo rendimiento tanto en entrenamiento como en prueba.

Tasa de Aprendizaje (learning rate init): Conecte esto con la Fase 2. Analice como influye en el número de iteraciones necesarias para que el Early Stopping se active.

La tasa de aprendizaje (learning rate) influye directamente en la velocidad y estabilidad del descenso de gradiente, como se observó en la Fase 2. Un learning rate bajo genera pasos pequeños, lo que aumenta el número de iteraciones necesarias para que el modelo converja, retrasando la activación del early stopping. Por el contrario, un learning rate alto puede provocar oscilaciones o divergencia, impidiendo que el error de validación mejore, lo que activa el early stopping de manera prematura.

Preguntas 3B

1. Compare el valor óptimo de alpha encontrado por el Grid- Search con lo que analizo en la sección de Regresión Ridge. ¿Existe una relación entre la complejidad de la red y la necesidad de regularización?

Respuesta

El valor óptimo obtenido a través de Grid Search muestra el balance entre la regularización y el ajuste, como se examinó en la regresión Ridge de la primera fase. La complejidad de la red está directamente relacionada con la necesidad de regularización: si el modelo es más complejo (más neuronas o capas), el riesgo de overfitting aumenta, así que se necesita un valor mayor de α para penalizar los pesos y optimizar la generalización.

2. Early Stopping: Explique cómo este mecanismo ayuda a optimizar el tiempo de cómputo y a prevenir el sobreajuste basado en sus resultados.

Respuesta

El early stopping posibilita la optimización del tiempo de cómputo, ya que interrumpe el entrenamiento cuando el modelo deja de progresar en el conjunto de validación, lo que evita iteraciones innecesarias. Asimismo, evita el sobreajuste al detectar el momento en que el modelo empieza a memorizar los datos de entrenamiento en vez de generalizarlos, deteniendo el proceso antes de que el error de validación aumente.

3. Conclusión de Negocio: Basándose en el mejor modelo encontrado, ¿cuál es el margen de error promedio que la empresa debería esperar al predecir sus ventas?
¿Es el modelo lo suficientemente robusto para decisiones presupuestales? Justifique

Respuesta

De acuerdo con el MAE, la compañía puede prever un margen de error medio de alrededor de 47 unidades al estimar sus ventas, basándose en el mejor modelo obtenido. No obstante, el RMSE de cerca de 69 unidades señala que en algunas situaciones existen errores más grandes. A pesar de que el modelo refleja una buena estabilidad y generalización entre prueba y entrenamiento, tiene limitaciones como la subestimación de las ventas elevadas y la sensibilidad a valores outliers.

Fase 4: Propagación hacia Adelante (Forward Propagation) Manual

Calculo manual:

Capa 1 (Oculta)

$$W^{(1)} = \begin{pmatrix} 0,2 & 0,5 & -0,1 \\ 0,8 & -0,3 & 0,4 \\ -0,5 & 0,1 & 0,2 \end{pmatrix} \quad b^{(1)} = \begin{pmatrix} 0,1 \\ -0,2 \\ 0,0 \end{pmatrix} \quad X = \begin{pmatrix} 0,5 \\ 0,3 \\ 0,2 \end{pmatrix}$$



1) Pontaje de Calculo Capa 1 (Oculta)

$$z = Wx + b$$

$$z^{(1)} = (0,2 \cdot 0,5 + 0,5) \cdot 0,3 + (-0,1) \cdot 0,2 + 0,1 = 0,33$$

$$z^{(2)} = (0,8 \cdot 0,5 + (-0,3) \cdot 0,3 + 0,4 \cdot 0,2 + (-0,2) = 0,19$$

$$z^{(3)} = (-0,5 \cdot 0,5 + 0,1 \cdot 0,3 + 0,2 \cdot 0,2) + 0 = 0,18$$

Activacion de capa Oculta

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

$$\frac{1}{1 + e^{-0,33}} = 0,5818$$

$$\frac{1}{1 + e^{-0,19}} = 0,5474$$

$$\frac{1}{1 + e^{-0,18}} = 0,4551$$

Puntaje Capa de Salida

$$W^{(2)} = \begin{pmatrix} 0,5 & -0,4 & 0,1 \\ 0,2 & 0,8 & -0,5 \\ 0,1 & 0,3 & 0,7 \end{pmatrix} \quad b^{(2)} = \begin{pmatrix} -0,1 \\ 0,2 \\ 0,1 \end{pmatrix} \quad X^{(2)} = \begin{pmatrix} 0,5818 \\ 0,5474 \\ 0,4551 \end{pmatrix}$$

$$z^{(1)} = (0,5 \cdot (0,5818) + (-0,4) \cdot 0,5474 + 0,1 \cdot 0,4551) + (-0,1) = 0,01745$$

$$z^{(2)} = (0,2 \cdot 0,5818 + 0,8 \cdot 0,5474 + (-0,5) \cdot 0,4551) + 0,2 = 0,5267$$

$$z^{(3)} = (0,1 \cdot 0,5818 + 0,3 \cdot 0,5474 + 0,7 \cdot 0,4551) + 0,1 = 0,5246$$

Probabilidad de Clase

$$\text{SoftMax}(z_i) = \frac{e^{z_i}}{\sum_{i=1} e^{z_i}}$$

$$\frac{e^{0,01745}}{e^{0,01745} + e^{0,5267} + e^{0,5246}} = 0,2312 \approx 23,12\%$$

$$\frac{e^{0,5267}}{e^{0,01745} + e^{0,5267} + e^{0,5246}} = 0,3847 \approx 38,47\%$$

$$\frac{e^{0,5246}}{e^{0,01745} + e^{0,5267} + e^{0,5246}} = 0,3839 \approx 38,39\%$$

Clase 1 (Bajo Impacto): 23,12%

Clase 2 (Impacto Medio): 38,47%

Clase 3 (Impacto Alto): 38,39%

Preguntas fase 4

1. Según las probabilidades obtenidas, ¿en qué categoría clasifica la red a esta campaña publicitaria?

Respuesta

Según los resultados obtenidos, la red clasifica la campaña publicitaria con un impacto alto (clase 3) que corresponde a una probabilidad del 38,39%.

2. ¿Por qué utilizamos Softmax en la última capa en lugar de una función lineal o una sigmoide simple? Explique en términos de la suma de las probabilidades.

Respuesta

Se utiliza la función Softmax en la última capa porque permite convertir las salidas de la red en una distribución de probabilidad válida, donde cada valor está entre 0 y 1 y la suma total de las probabilidades es igual a 1. A diferencia de una función lineal, que no limita los valores, o de la función sigmoide, que trata cada salida de manera independiente y no garantiza que sumen 1, Softmax normaliza los resultados haciendo que las clases compitan entre sí. Esto es lo ideal en problemas de clasificación multiclase, debido a que permite interpretar la salida como probabilidades y seleccionar la clase más probable.

3. ¿Qué sucedería con la capacidad de representación de la red si todos los vectores de sesgo (b) fueran cero?

Respuesta

Si todos los vectores de sesgo fueran cero, la red neuronal perdería capacidad de representación, ya que las funciones que puede aprender estarían restringidas a pasar por el origen. Esto limita la flexibilidad del modelo para ajustar los datos, ya que no podría desplazar las fronteras de decisión de manera independiente. Como resultado, la red tendría dificultades para capturar patrones complejos en los datos.

Fase 5: Evaluación de Modelos y Toma de Decisiones (Caso: Mantenimiento Predictivo)

Preguntas fase 5A

1. Si el modelo indica que los errores en la Clase 1 (Fallo) pesaran aproximadamente 14.7 veces más que en la Clase 0, ¿que intenta corregir el algoritmo al configurar el parámetro class weight durante el entrenamiento?

```
Pesos de Clase calculados: {0: np.float64(0.51753137533963), 1: np.float64(14.760147601476016)}
Esto significa que los errores en la Clase 1 (Fallo) pesarán ~14.7 veces más.

Entrenando la red...
Epoch 1/30
100/100 — 6s 17ms/step - Recall: 0.8704 - accuracy: 0.4925 - loss: 0.5192 - val_recall: 1.0000 - val_accuracy: 0.9200 - val_loss: 0.5347
Epoch 2/30
100/100 — 1s 7ms/step - Recall: 0.9352 - accuracy: 0.8053 - loss: 0.3159 - val_recall: 1.0000 - val_accuracy: 0.9975 - val_loss: 0.3227
Epoch 3/30
100/100 — 1s 7ms/step - Recall: 0.9398 - accuracy: 0.9731 - loss: 0.2315 - val_recall: 1.0000 - val_accuracy: 0.9987 - val_loss: 0.1984
Epoch 4/30
100/100 — 1s 9ms/step - Recall: 0.9537 - accuracy: 0.9937 - loss: 0.1623 - val_recall: 1.0000 - val_accuracy: 0.9987 - val_loss: 0.1179
Epoch 5/30
100/100 — 1s 11ms/step - Recall: 0.9630 - accuracy: 0.9969 - loss: 0.1194 - val_recall: 1.0000 - val_accuracy: 0.9987 - val_loss: 0.0688
Epoch 6/30
100/100 — 1s 9ms/step - Recall: 0.9583 - accuracy: 0.9970 - loss: 0.1050 - val_recall: 1.0000 - val_accuracy: 0.9994 - val_loss: 0.0512
Epoch 7/30
100/100 — 1s 10ms/step - Recall: 0.9583 - accuracy: 0.9969 - loss: 0.1071 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0412
Epoch 8/30
100/100 — 1s 9ms/step - Recall: 0.9583 - accuracy: 0.9980 - loss: 0.1002 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0385
Epoch 9/30
100/100 — 1s 9ms/step - Recall: 0.9676 - accuracy: 0.9981 - loss: 0.0857 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0337
Epoch 10/30
100/100 — 2s 15ms/step - Recall: 0.9676 - accuracy: 0.9981 - loss: 0.0830 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0299
Epoch 11/30
100/100 — 1s 11ms/step - Recall: 0.9630 - accuracy: 0.9986 - loss: 0.0951 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0344
Epoch 12/30
100/100 — 2s 16ms/step - Recall: 0.9676 - accuracy: 0.9987 - loss: 0.0571 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0271
Epoch 13/30
100/100 — 2s 9ms/step - Recall: 0.9630 - accuracy: 0.9980 - loss: 0.0916 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0289
Epoch 14/30
100/100 — 2s 11ms/step - Recall: 0.9676 - accuracy: 0.9986 - loss: 0.0818 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0282
Epoch 15/30
100/100 — 1s 9ms/step - Recall: 0.9676 - accuracy: 0.9994 - loss: 0.0791 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0262
Epoch 16/30
100/100 — 1s 9ms/step - Recall: 0.9630 - accuracy: 0.9981 - loss: 0.0826 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0279
Epoch 17/30
100/100 — 0s 3ms/step - Recall: 0.9676 - accuracy: 0.9981 - loss: 0.0756 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0270
Epoch 18/30
100/100 — 0s 3ms/step - Recall: 0.9676 - accuracy: 0.9981 - loss: 0.0756 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0270
Epoch 19/30
100/100 — 0s 3ms/step - Recall: 0.9676 - accuracy: 0.9987 - loss: 0.0681 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0217
Epoch 20/30
100/100 — 0s 3ms/step - Recall: 0.9676 - accuracy: 0.9987 - loss: 0.0678 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0245
Epoch 21/30
100/100 — 0s 3ms/step - Recall: 0.9630 - accuracy: 0.9984 - loss: 0.0687 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0231
Epoch 22/30
100/100 — 0s 3ms/step - Recall: 0.9630 - accuracy: 0.9984 - loss: 0.0809 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0253
Epoch 23/30
100/100 — 1s 3ms/step - Recall: 0.9676 - accuracy: 0.9987 - loss: 0.0735 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0218
Epoch 24/30
100/100 — 0s 3ms/step - Recall: 0.9676 - accuracy: 0.9987 - loss: 0.0883 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0283
Epoch 25/30
100/100 — 0s 3ms/step - Recall: 0.9676 - accuracy: 0.9989 - loss: 0.0723 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0259
Epoch 26/30
100/100 — 0s 3ms/step - Recall: 0.9676 - accuracy: 0.9986 - loss: 0.0821 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0283
Epoch 27/30
100/100 — 0s 3ms/step - Recall: 0.9676 - accuracy: 0.9987 - loss: 0.0646 - val_recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0242
Epoch 28/30
```

Respuesta

El uso del parámetro `class_weight` busca corregir el desbalance de clases presente en el dataset, donde la clase de fallos es mucho menos frecuente que la de no fallos. Al asignar un peso aproximadamente 14.7 veces mayor a la clase 1, el algoritmo penaliza más los errores asociados a esta clase, especialmente los falsos negativos. Esto obliga al modelo a


prestar mayor atención a la detección de fallos, evitando que se incline hacia la clase mayoritaria.

2. La Trampa de la Exactitud: Explique por qué en este caso un Accuracy del 95% podría considerarse un resultado deficiente para la gestión de mantenimiento si el modelo no logra detectar los fallos reales.

Respuesta

En un contexto de mantenimiento predictivo con datos desbalanceados, un accuracy del 95% puede ser engañoso, ya que el modelo puede lograr este valor simplemente prediciendo siempre la clase mayoritaria (no falla). Esto implica que no está detectando los fallos reales, lo cual es crítico en este tipo de aplicaciones. El problema radica en que el accuracy no diferencia entre tipos de error, y en este caso los falsos negativos (no detectar una falla) tienen un costo mucho mayor.

Interpretación de la Matriz de Confusión



Utilice la matriz de confusión generada por el heatmap. Suponga que para su planta de producción, el costo de una reparación no planificada (Fallo Real no detectado) es de USD 5,000 y el costo de una inspección preventiva innecesaria (Falsa Alarma) es de USD 200.

A partir de los valores obtenidos en la matriz de confusión (TN, FP, FN, TP), calcule:

- Precision (Precisión):

$$\frac{TP}{TP+FP} = \frac{66}{66+0} = 1 = 100\%$$

¿Qué tan confiable es el modelo cuando emite una alerta de falla?

El modelo Es confiable en un 100% cuando emite alerta de falla

- Recall (Sensibilidad):

$$\frac{TP}{TP + FN} = \frac{66}{66 + 2} = 0,97 = 97\%$$

¿Qué porcentaje de los fallos reales totales logró capturar el modelo?

El modelo logro capturar el 97% de los fallos reales

- Costo Total de Error:

$$Costo = (FN * 5000) + (FP * 200) = (2 * 5000) + (0 * 200) = 10000$$

Preguntas de reflexión y negocio fase 5

1. En el contexto de evitar paradas de línea críticas, ¿preferiría usted un modelo con un Recall del 98% pero una Precisión del 60%, o viceversa? Justifique su respuesta basándose en los costos calculados anteriormente.

Respuesta

En el contexto de mantenimiento predictivo, es preferible un modelo con alto recall (98%) aunque tenga una precisión menor (60%). Esto se debe a que el costo de no detectar una falla (USD 5000) es significativamente mayor que el costo de una falsa alarma (USD 200).

2. Curva de Aprendizaje: Observe la gráfica de loss (perdida) y accuracy durante el entrenamiento. ¿Considera que 30 épocas son suficientes para que el modelo converja? ¿Qué sucede con el error de validación comparado con el de entrenamiento?

Respuesta

El modelo muestra un proceso de aprendizaje adecuado, donde tanto la pérdida de entrenamiento como la de validación disminuyen de manera similar, lo que indica una buena capacidad de generalización. Aunque el algoritmo no alcanza una convergencia completa en 30 épocas, el comportamiento de las métricas sugiere que el modelo ha aprendido patrones relevantes sin evidencias claras de sobreajuste.

Conclusión Final del Taller

3. Tras recorrer desde la regresión analítica hasta la clasificación con redes neuronales, ¿cómo puede el uso de métricas avanzadas (como el Recall) transformar la rentabilidad de una empresa de manufactura?

Durante el desarrollo del taller, quedó claro cómo la transición desde modelos analíticos, como la regresión con regularización, hacia redes neuronales posibilita tratar problemas industriales de mayor complejidad. No obstante, el impacto real en la toma de decisiones no depende tanto del modelo que se emplee, sino de la elección apropiada de las métricas de evaluación.

El uso de métricas avanzadas, como el Recall, es esencial en situaciones de manufactura, por ejemplo, en el mantenimiento predictivo. Esto se debe a que permite calcular la habilidad del modelo para identificar sucesos críticos, tales como los fallos de máquinas. El recall, a diferencia del accuracy, que puede ser engañoso en situaciones desbalanceadas, se enfoca en detectar fallos reales, lo cual reduce los falsos negativos.

Esto repercute directamente en la rentabilidad de la compañía, ya que no detectar un fallo puede acarrear gastos mucho más altos (daños a los equipos, paradas no programadas, pérdidas de producción) si se compara con el coste de una falsa alarma. Por lo tanto, mejorar el modelo con el objetivo de maximizar el recall hace posible disminuir estos sucesos críticos, lo cual mejora la continuidad en las operaciones y reduce las pérdidas económicas.